資料探勘 DATA MINING Project 1

Q36071059 蔡榮漾

1. IBM Quest Data Generator.exe:

此程式主要之參數有三個:ntrans、tlen 與 nitems,分別意義如下

ntrans transactions 數量

tlen 每筆 transactions 平均 items 數

nitems items 種類數

另 IBM Quest Data Generator.exe 程式中輸入的 ntrans 與 nitems 參數會<mark>再乘上 1000</mark>才是實際數字,使用時須注意,此外參數<mark>可為小數</mark>(ex.0.1);也可利用 fname 參數自訂檔案名稱,否則使用默認檔案名稱。

本報告使用參數為:

lit -ntrans 0.1 -tlen 5 -nitems 0.01

產生之資料格式如下(只取前面小部分):

1	1	Λ
1 1 1 1 2 2 2 2 3 3 4 4 4 4 5 5	1 1 1 1 1 2 2 2 2 3 3 4 4 4 4 5 5	06789456807467805
1	1	7
1	1	χ
1	1	o o
2	2	1
2	<u>4</u>	4
<u>ا</u>	<u> </u>	2
4	Δ	0
7	7	δ
3	3	Ō
3	3	7
4	4	4
4	4	6
4	4	7
4	4	8
5	5	0
ς	7	~

根據個人理解,其意義應為:

```
TID ITEMS

1     0,6,7,8,9

2     4,5,6,8

3     0,7

4     4,5,7,8
.....
```

由於 IBM Quest Data Generator.exe 產生之資料格式難以直接利用, 先將其整理,使用以下程式碼(Python2.7):

```
def datatrans():
    f = open('data.ntrans_0.1.tlen_5.nitems_0.01', 'r')
    input=f.read()
    list=input.split()
    data=[list[i:i+3] for i in range(0,len(list),3)] #list fragment
    data2=[]
    for i in range(0,len(list)/3):
        j=3*i+2
        data2.append(list[j])
    data3=[]
    data4=[]
    for i in range(1,len(list)/3):
       data3.append(data2[i-1])
       if(int(list[i*3])-int(list[(i-1)*3])==1):
         data4.append(data3)
         data3=[]
    data3.append(data2[i])
    data4.append(data3)
    return data4
```

Figure 1

先讀取資料檔案,將內容放至一個串列 list,再將 list 轉為巢狀串列把每筆資料分開放至 data,去掉 TID 放至 data2,最後以巢狀串列區隔每筆不一樣的 transactions。

得到之 data4 如下:



Figure 2 至此資料之處理暫告一段落,後續將提到此 datatrans()函式如何使用。

2. WEKA:

由於 WEKA 似乎只吃 .arff 檔案, 且有特定格式,經查詢後,撰寫程式 trans_arff.py, 將先前 IBM Quest Data Generator.exe 所產生之原始資料 data.ntrans 0.1.tlen 5.nitems 0.01 轉為稀疏型資料 weka data.arff。

weka data.arff 之格式如下:

```
@relation 'TestID'
     @attribute 0 {F, T}
    @attribute 1 {F, T}
    @attribute 2 {F, T}
    @attribute 3 {F, T}
     @attribute 4 {F, T}
    @attribute 5 {F, T}
   @attribute 6 {F, T}
   @attribute 7 {F, T}
@attribute 8 {F, T}
@attribute 9 {F, T}
   @data
   {0 T, 6 T, 7 T, 8 T, 9 T}
    {4 T, 5 T, 6 T, 8 T}
     {0 T, 7 T}
    {4 T, 6 T, 7 T, 8 T}
17 {0 T, 5 T, 7 T, 8 T, 9 T}
   {0 T, 1 T, 3 T, 4 T, 5 T, 7 T, 8 T, 9 T}
   {0 T, 3 T, 4 T, 5 T, 6 T, 8 T}
    {9 T}
    {0 T, 5 T, 6 T, 8 T, 9 T}
     {0 T, 3 T, 7 T, 8 T, 9 T}
     {0 T, 3 T, 6 T, 8 T, 9 T}
     {0 T, 3 T, 4 T, 5 T, 6 T, 8 T, 9 T}
    {0 T, 3 T, 8 T, 9 T}
```

Figure 3

簡單舉例,此 data(data.ntrans_0.1.tlen_5.nitems_0.01)共有 0~9 10 種 items,第一行必須先為此筆資料(@relation)命名,

再來則要列出所有 items(@attribute 0 {F, T}~@attribute 9 {F, T}),

然後以一行@data 隔開,此後一行放置一個 transaction。

先使用 WEKA 對此資料進行測試,進行 FP Growth,使用參數為: FPGrowth -P 2 -I -1 -N 10 -T 0 -C 0.7 -D 0.05 -U 1.0 -M 0.5

得到之結果:

```
=== Run information ===
             weka.associations.FPGrowth -P 2 -I -1 -N 10 -T 0 -C 0.7 -D 0.05 -U 1.0 -M 0.5
Scheme:
Relation:
             TestID
Instances:
Attributes: 10
              0
              1
              3
              4
              5
              6
              8
              9
=== Associator model (full training set) ===
FPGrowth found 6 rules (displaying top 6)
1. [3=T]: 56 ==> [8=T]: 49 <conf:(0.88)> lift:(1.06) lev:(0.03) conv:(1.24)
2. [9=T]: 59 ==> [8=T]: 51 <conf:(0.86)> lift:(1.05) lev:(0.03) conv:(1.16)
3. [3=T]: 56 ==> [9=T]: 43 <conf:(0.77)> lift:(1.11) lev:(0.05) conv:(1.22)
4. [9=T]: 59 ==> [3=T]: 43 <conf:(0.73)> lift:(1.11) lev:(0.05) conv:(1.18)
5. [8=T]: 70 ==> [9=T]: 51 \langle conf: (0.73) \rangle lift: (1.05) lev: (0.03) conv: (1.07)
6. [8=T]: 70 ==> [3=T]: 49 <conf:(0.7)> lift:(1.06) lev:(0.03) conv:(1.09)
```

Figure 4

以 Apriori 演算法進行驗證(minConf:0.7 minSup 0.5),得知 WEKA 操作上沒有 問題,產生之關聯法則與各信賴度大致相同。

```
問題,<sub>连</sub>
minConf=0.7;
frozenset(['8']
hozenset(['9'
ot(['3'
                                                                                9']) conf: 0.728571428571
8']) conf: 0.984499
                                          --> frozenset(['9'
                                        --> frozenset(['8']) conf: 0.864406779661

--> frozenset(['9']) conf: 0.767857142857

--> frozenset(['3']) conf: 0.728813559322

--> frozenset(['8']) conf: 0.875
   rozenset(['3
rozenset(['9',
                                        --> frozenset(['9'
--> frozenset(['3',
                           '3'
   rozenset(
 frozenset
                                                                                             conf:
```

3. FP-Growth 之實作(fpg.py):

建立 FP-tree:

在開始建樹之前,需先決定節點構造:

```
class treeNode:
def __init__(self,nameValue, numOccur, parentNode):
self.name = nameValue
self.count = numOccur
self.parent = parentNode
self.children = {}
self.nodeLink = None

def inc(self, numOccur):
self.count += numOccur

def disp(self, ind = 1):
print " " * ind, self.name, " ",self.count
for child in self.children.values():
child.disp(ind + 1)
```

Figure 5

```
name 元素名稱
count 元素出現次數
parent 指向子點
children 指向父點
nodeLink 指向下一相同名稱節點
inc() 計算元素出現次數
disp() 輸出節點&子點的 FP 結構
建立 FP-tree:
```

```
lef createTree(dataSet, minSup=1): #creat fp-tree
   headerTable = {}
   for trans in dataSet:
       for item in trans:
            headerTable[item] = headerTable.get(item, 0) + dataSet[trans]
   for k in headerTable.keys(): #remove item < minSup</pre>
       if headerTable[k] < minSup:</pre>
           del(headerTable[k])
   freqItemSet = set(headerTable.keys())
   if len(freqItemSet) == 0: #if [] return none
   for k in headerTable:
     headerTable[k] = [headerTable[k], None]
   retTree = treeNode('Null Set', 1, None)
for tranSet, count in dataSet.items():
            if item in freqItemSet:
                 localD[item] = headerTable[item][0]
        if len(localD) > 0:
            ordered Items = [v[\emptyset] \ for \ v \ in \ sorted(local D. items(), \ key=lambda \ p: \ p[1], \ reverse=True)] \ \#sorted(local D. items(), \ key=lambda \ p: \ p[1], \ reverse=True)]
            updateTree(orderedItems, retTree, headerTable, count)
   return retTree, headerTable
```

Figure 6

建立 Conditional FP-tree:

```
def mineTree(inTree,headerTable,minSup,preFix,freqItemList):

bigL = [v[0] for v in sorted(headerTable.items(),key = lambda p:p[1])]

for basePat in bigL:

newFreqSet = preFix.copy()

newFreqSet.add(basePat)

freqItemList.append(newFreqSet)

condPattBases = findPrefixPath(basePat, headerTable[basePat][1])

myConTree,myHead = createTree(condPattBases, minSup)

if myHead != None:

print 'conditional tree for :', newFreqSet

myConTree.disp()

mineTree(myConTree, myHead, minSup, newFreqSet, freqItemList)
```

Figure 7

此處流程大致上是,藉由前處 creatTree() 函式所建立之 FP-tree 得到 CPB(Conditional Pattern Base),並利用 CPB 建立 Conditional FP-tree,然後持續遞迴,直到樹只包含一個 item。

主程式:

```
if __name__ == "__main__":
    dataSet = datatrans()
    freqItems = fpGrowth(dataSet)
    print freqItems
```

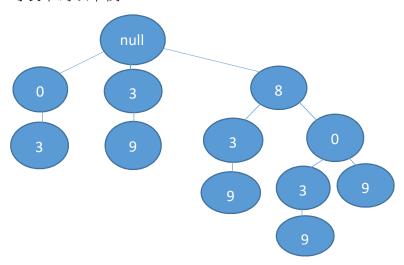
Figure 8

此處利用 datatrans()將 IBM Quest Data Generator.exe 產生之數據轉換格式並放到變數 dataSet 供其他函式使用,之後運行 fpGrowth()函數。

<mark>樹</mark>的顯示方式:

Figure 9

以此為例,可表示為以下樹:



得到之<mark>頻繁項集</mark>:

minSup 為 30 時, Frequent Patterns 為:

[set(['0']), set(['3']), set(['8', '3']), set(['9']), set(['9', '8']), set(['8'])] minSup 為 20 時,Frequent Patterns 為:

[set(['4']), set(['6']), set(['8', '6']), set(['7']), set(['8', '7']), set(['5']), set(['3', '5']), set(['8', '5']), set(['0']), set(['0', '3']), set(['9', '0']), set(['0', '8']), set(['3']), set(['9', '3']), set(['9', '8']), set(['8', '3']), set(['9']), set(['9', '8']), set(['8'])]

minSup 為 10 時,Frequent Patterns 為:



觀察得知,FP-tree 建構時所設立的 min support 值越高,確實如預想的會讓頻繁項集數量減少,亦可作為<mark>驗證</mark>程式正確性的步驟之一。

利用頻繁項集找尋關聯法則與計算 confident:

```
for item_j in freqItems:
    if item_i != item_j:
        item_i_count=0
        item_j_count=0
        if not (checkIsexist(item_i, item_j) or checkIsexist(item_j, item_i) or checkAnyexist(item_i, item_j)):
                if checkIsexist(item_i, datas):
                    item_i_count += 1
                 if checkIsexist(item_i, datas) and checkIsexist(item_j, datas):
                    item_j_count += 1
            if item_i_count != 0 and item_j_count != 0 and item_j_count/item_i_count>=0.5 and item_j_count!=1:
```

Figure 10

得到之結果:

```
(*4*) ---> (*3*) conf : 0.75
(*4*) ---> (*9*) conf : 0.7142857142857143
(*4*) ---> (*8*) conf : 0.7142857142857143
(*4*) ---> (*8*) conf : 0.85714285714285711
(*6*) ---> (*8*) conf : 0.7096774193548387
(*6*) ---> (*9*) conf : 0.7419354838709677
(*6*) ---> (*8*, *9*) conf : 0.7096774193548387
(*6*) ---> (*8*, *9*) conf : 0.87096774193548387
(*5*) ---> (*8*) conf : 0.8709677419354839
(*5*) ---> (*8*) conf : 0.8709677419354839
(*5*) ---> (*8*) conf : 0.7428571428571429
(*5*) ---> (*8*) conf : 0.8205128205128205
(*0*) ---> (*9*) conf : 0.7608695652173914
(*0*) ---> (*8*, *9*) conf : 0.717391304347826
(*0*) ---> (*8*, *9*) conf : 0.8478260869565217
(*1*) ---> (*8*, *9*) conf : 0.8
(*1*) ---> (*3*) conf : 0.8
(*1*) ---> (*3*) conf : 0.8
(*1*) ---> (*8*) conf : 0.8
(*1*) ---> (*8*) conf : 0.88
(*3*) ---> (*8*) conf : 0.8837209302325582
(*3*, *8*) ---> (*8*) conf : 0.8837209302325582
(*3*, *8*) ---> (*8*) conf : 0.7755102040816326
(*9*) ---> (*8*) conf : 0.77288135593220338
(*9*) ---> (*8*) conf : 0.7288135593220338
(*9*) ---> (*8*) conf : 0.7288135593220338
(*9*) ---> (*8*) conf : 0.7450980392156863
(*8*, *9*) ---> (*3*) conf : 0.7450980392156863
```

Figure 11

與 WEKA 所得之結果比較:

```
=== Run information ===
           weka.associations.FPGrowth -P 2 -I -1 -N 10 -T 0 -C 0.7 -D 0.05 -U 1.0 -M 2.0
Scheme:
           TestID
Instances:
           85
Attributes:
          10
=== Associator model (full training set) ===
FPGrowth found 11 rules (displaying top 10)
1. [9=T, 3=T]: 43 ==> [8=T]: 38 <conf:(0.88)> lift:(1.07) lev:(0.03) conv:(1.26)
5. [8=T, 3=T]: 49 \implies [9=T]: 38 < conf: (0.78) > lift: (1.12) lev: (0.05) conv: (1.25)
5. [0-1, 3-1]. 49 --> [3-1]. 50 (conf.(0.76) first (1.11) fev.(0.05) conf.(1.22) for [0-2]: 46 --> [9-1]: 35 (conf.(0.76) fift:(1.11) lev.(0.04) conv.(1.17)
```

Figure 12

發現兩者產生之關聯法則與其 conf 大致相同。 列出前三者為例進行比較:

[9,3]-->[8] conf:0.88

[3]-->[8] conf:0.88

[9]-->[8] conf:0.86

確實到小數點第三位為止並無太大差異,

可知撰寫之程式所產生的結果應該正確;

唯產生之關聯法則數目有差異,

此部分是否為參數設定上之差異,還可進一步測試。